



---

# Mission de fin d'études

## Find Your Way

---

AUBAY

*Maître de stage :*  
Nathan CANTAT

*Jury de stage :*  
Arnaud BANNIER

*Auteur :*  
**Nicolas CISTERNAS**

28 février - 31 août 2022

## Résumé

Le projet Find Your Way a pour but de guider des personnes malvoyantes en milieu intérieur. Ce document relate le travail effectué autour de cette thématique dans le cadre de mon stage de fin d'études chez Aubay, en se focalisant sur la partie localisation et guidage de l'utilisateur. Un état de l'art concernant le sujet de la localisation et de la cartographie locale en temps réel est présenté. Ensuite une preuve de concept se basant sur une méthode en sources libres, contenant les améliorations que nous avons pu ajouter avec mon groupe est expliquée. Enfin ce document explique le déroulement de la phase projet au sein de la cellule Innov' de l'entreprise Aubay pour démontrer le résultat d'une collaboration entre 11 stagiaires. Le lecteur pourra y trouver des informations concernant ORB-SLAM3, FAST, les points d'intérêts, la création d'un protocole de communication, le développement de l'interface graphique et les problèmes que l'on peut rencontrer sur ce genre de projet multidisciplinaire.

## **Abstract**

The Find Your Way project aims to guide visually impaired people in indoor environments. This document relates the work done on this topic during my internship at Aubay, focusing on the localization and user guidance part. A state of the art concerning the subject of localization and real-time mapping is presented. Then a proof of concept based on an open source method, containing the improvements that we could add with my group is explained. Finally, this document explains the project phase within the Innov's cell of Aubay to show the result of a collaboration between 11 trainees. The reader can find information about ORB-SLAM3, FAST, the points of interest, the creation of a communication protocol, the development of the graphic interface and the problems that can be encountered on this kind of multidisciplinary project.

# Table des matières

<b>1</b>	<b>Remerciements</b>	<b>4</b>
<b>2</b>	<b>Introduction et contexte</b>	<b>5</b>
<b>3</b>	<b>État de l'art</b>	<b>7</b>
3.1	Recherches bibliographiques . . . . .	7
3.1.1	Wearable Travel Aid for Environment Perception and Navigation of Visually Impaired People . . . . .	7
3.1.2	CDSFusion : Dense Semantic SLAM for Indoor Environment Using CPU Computing . . . . .	9
3.1.3	Towards Real-time Semantic RGB-D SLAM in Dynamic Environments	11
3.1.4	ORB-SLAM3 : An Accurate Open-Source Library for Visual, Visual-Inertial and Multi-Map SLAM . . . . .	11
3.2	Synthèse . . . . .	14
3.3	Conclusion . . . . .	15
<b>4</b>	<b>Les dimensions techniques du projet</b>	<b>16</b>
4.1	Phase de preuve de concept . . . . .	16
4.1.1	Installation . . . . .	16
4.1.2	Calibration . . . . .	17
4.1.3	Recherche de chemin . . . . .	18
4.1.4	Test et résultats . . . . .	22
4.1.5	Difficultés rencontrées . . . . .	23
4.1.6	Conclusion . . . . .	23
4.2	Phase projet . . . . .	23
4.2.1	Protocole de communication . . . . .	23
4.2.2	Développement de l'application . . . . .	25
4.2.3	Conclusion . . . . .	27
<b>5</b>	<b>Les dimensions humaines et managériales</b>	<b>28</b>
5.1	Le plan humain . . . . .	28
5.2	Le plan managérial . . . . .	28
<b>6</b>	<b>Conclusion</b>	<b>30</b>
6.1	Le bilan technique . . . . .	30
6.2	Le bilan humain . . . . .	30
6.3	Possibilités d'évolution du projet . . . . .	31
6.4	Perspectives d'évolution professionnelles . . . . .	31
<b>7</b>	<b>Bibliographie</b>	<b>32</b>
<b>8</b>	<b>Annexes</b>	<b>33</b>

# 1 Remerciements

Je remercie Éric REMILLERET et Nathan CANTAT, mes maîtres de stage, pour m'avoir donné l'opportunité de rejoindre Aubay Innov' ainsi que pour l'aide à la relecture de ce rapport.

Je remercie Anne-France GALLAND, qui a largement contribué à la phase de suivi et d'organisation du projet, par ses interventions lors des réunions hebdomadaires et pour le temps qu'elle a pris pour la relecture de ce rapport.

Je remercie Jean-Philippe CUNNIET, mon tuteur de stage ainsi qu'Arnaud BANNIER, le jury de cette mission de fin d'études, pour le temps qu'ils ont passé à relire et évaluer ce rapport de stage ainsi que la soutenance de stage.

Je tiens à remercier toute l'équipe avec laquelle j'ai travaillé durant mon stage : Nicolas GUILLERMAIN et Mathieu MONNERET avec qui j'ai travaillé lors de la phase d'état de l'art et de preuve de concept. Mélissa WANG et Jeffrey MENUDEYER avec qui j'ai principalement travaillé lors de la phase projet. Jean-Baptiste CHANIER, Victor CHAVEROT, Jean-Noël CLINK, Ophélie PHONCHAREUN, Miora RASOLOFONERA et Rémi VIDAL avec qui j'ai échangé tout au long du stage concernant leurs parties du projet.

Je tiens également à remercier la direction générale d'Aubay pour leur accueil et leur écoute ainsi qu'Ophélie CHEVALIER, campus manager, pour tous les événements qu'elle a pu organiser et qui ont permis d'établir un climat chaleureux entre les différents groupes.

Enfin, je remercie les autres étudiants d'Aubay Innov' ainsi que tous les encadrants avec lesquels j'ai eu l'occasion d'échanger aussi bien humainement que techniquement.

## 2 Introduction et contexte

Mon stage s'est déroulé dans une entreprise appelée Aubay, pour une durée de 6 mois (du 28 février 2022 au 31 août 2022). En détail, Aubay est une entreprise de services numériques (ESN) qui a été fondée par Christian Aubert en 1998 et dont le siège social est situé au 13 rue Louis Pasteur à Boulogne-Billancourt. L'entreprise est spécialisée dans les domaines liés à la finance, à l'assurance et à la banque et est également impliquée dans divers marchés, tels que les télécoms, les services, les réseaux, l'énergie et les transports. Aubay accompagne la transformation et la modernisation des systèmes d'information de ses clients. Ils opèrent sur des marchés à forte valeur ajoutée, en France comme en Europe. C'est un acteur référent de la transformation digitale. Son secteur d'activité est centré autour du conseil sur tout type de projet technologique. C'est une ESN cotée en Bourse (SBF 250) et 46% du capital est détenu par les managers. Les chiffres clés concernant Aubay sont présentés dans la Figure 1 ci-après. En 2022, l'entreprise emploie 7306 personnes, dont 2728 en France. Selon son site internet, Aubay est implantée dans 7 pays européens, et a réalisé un chiffre d'affaires de 470,6 M€ en 2021. D'ailleurs, ces dernières années, l'entreprise a connu une forte croissance de 10,4% en 2021, qui coïncide avec une augmentation constante des effectifs de l'entreprise, passant de 4600 employés en 2015 à plus de 7000 aujourd'hui.

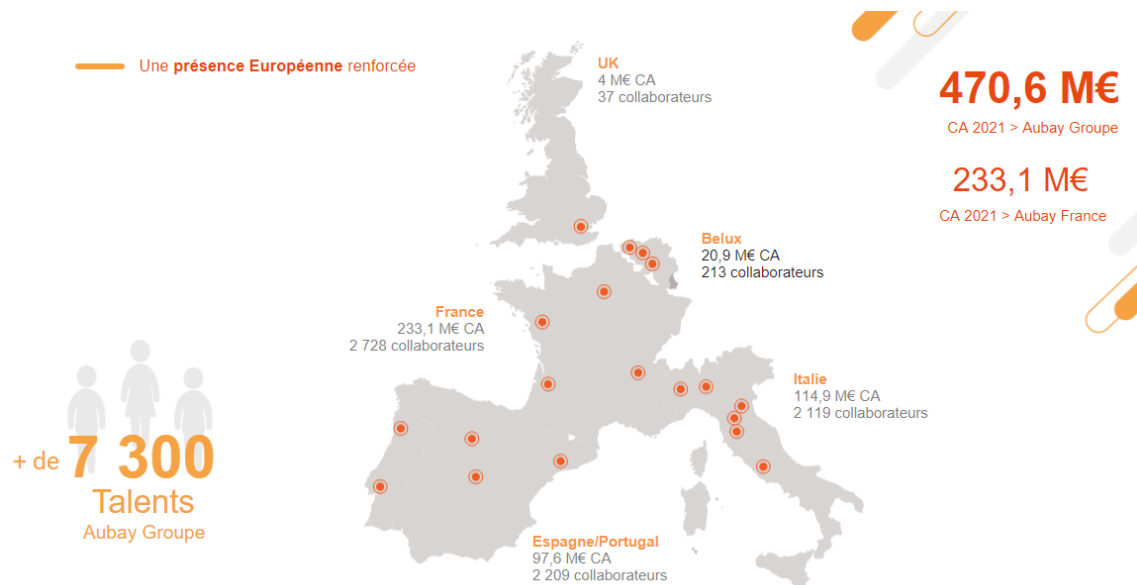


FIGURE 1 – Chiffres clés pour Aubay en 2021.

J'ai eu le privilège d'effectuer mon stage au sein de l'unité "Aubay Innov'" qui est la division d'Aubay France dédiée à la recherche et à l'innovation. Ses membres sont impliqués dans différents projets, chacun lié à la data science, l'analyse de données ou tout autre domaine liés aux nouvelles technologies numériques. L'objectif de l'unité est d'acquérir les connaissances et le savoir-faire pour construire des solutions durables et innovantes adaptées aux besoins futurs des clients. Les projets dirigés dans la cellule innovation d'Aubay ne sont donc soumis à aucun client pendant leur réalisation, ce qui laisse l'opportunité

aux stagiaires d'expérimenter autant qu'ils le souhaitent durant leur stage. Chaque année, cette unité donne la chance à des dizaines de stagiaires d'améliorer ou de perfectionner leurs connaissances relatives à la science des données en leur laissant l'opportunité de découvrir et d'expérimenter les technologies les plus innovantes disponibles dans les domaines de la recherche. Par ailleurs, l'unité "Aubay Innov'" est largement considérée comme une source de recrutement pour l'entreprise, qui a souhaité cette année engager environ 800 nouveaux collaborateurs en France.

C'est dans ce cadre que ma mission de fin d'études a débuté. Le projet "Find Your Way" (FYW) représente l'expérience que je vais détailler dans ce document. Il a été lancé en février 2022 avec pour objectif de créer une application basée sur des algorithmes reconnaissant l'environnement immédiat d'un utilisateur malvoyant pour le guider. Ce guidage doit pouvoir se faire vers des lieux enregistrés et l'avertir d'obstacles présents sur son chemin avec un système de commandes vocales.

Les systèmes d'aide automatisés au déplacement de personnes malvoyantes existent déjà sur le marché et nécessitent de fournir une carte du bâtiment avec les lieux importants préalablement renseignés afin de rendre le guidage possible. Ce projet vise à s'affranchir de cette contrainte afin de permettre une plus grande polyvalence pour ce genre d'outil. Le projet a été séparé en plusieurs parties délimitées par des dates clés qui sont présentées dans la Figure 2 avec les livrables associés à chaque fin de phase. La prise en main du projet a démarré début février, s'en est suivi la partie concernant les états de l'art (EA sur la Figure 2) qui devait être réalisée entre mi-février et mi-mars en parallèle du Design Thinking, qui nous a permis de cadrer et définir le projet par rapport aux besoins de l'application et les tâches à accomplir. La phase de preuve de concept qui a suivi a duré jusqu'à mi-mai. Nous sommes ensuite passés à la phase projet afin de concevoir l'application de démonstration nécessaire à la journée des stagiaires (JDS) du 7 juillet, moment phare pour le pôle innovation de chez Aubay où tous les stagiaires présentent leurs projets lors d'une démonstration auprès des directeurs généraux et équipes commerciales de l'entreprise.

J'ai réalisé ce projet dans une équipe de 11 stagiaires, tous en stage de fin d'études. Étant donné les multiples parties concernant le projet, à savoir : la détection d'objets, la localisation de l'utilisateur et la gestion des interactions vocales, nous avons dû nous séparer en 3 groupes. J'ai personnellement travaillé sur la partie s'intéressant à la localisation et le guidage de l'utilisateur dans son environnement.

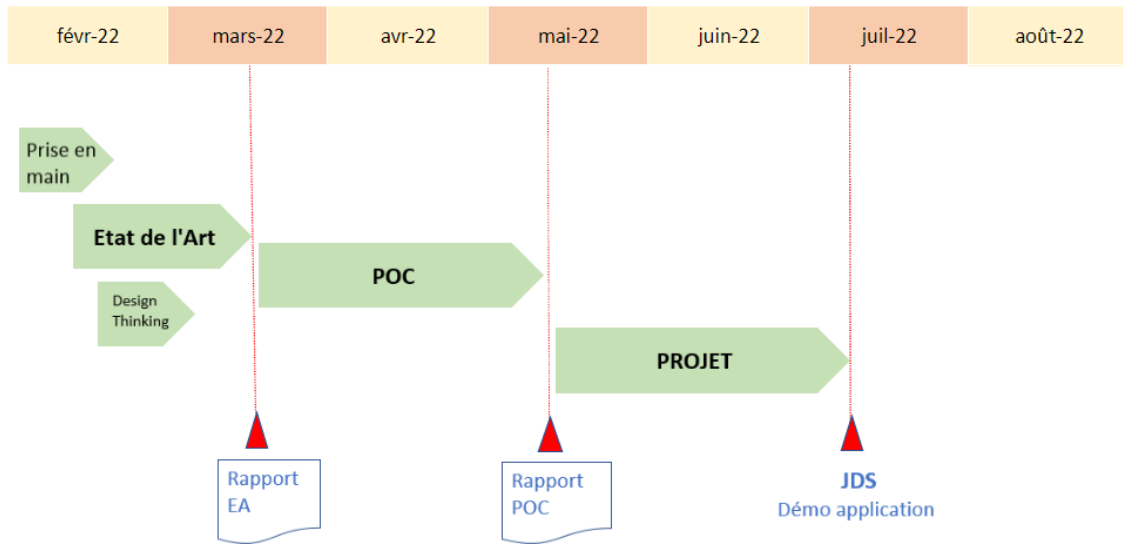


FIGURE 2 – Planning prévisionnel du projet FYW.

### 3 État de l'art

#### 3.1 Recherches bibliographiques

Dans cette section je présente les recherches bibliographiques que j'ai pu effectuer avec mon groupe lors de la phase d'état de l'art. Cet état de l'art concerne la partie de localisation et de guidage de l'utilisateur. Nous avons retenu 8 publications, nous les avons confrontées et comparées afin de n'en sélectionner qu'une sur laquelle nous allons nous concentrer lors de la phase de preuve de concept. Je présente ici 4 des publications les plus pertinentes sur le sujet.

##### 3.1.1 Wearable Travel Aid for Environment Perception and Navigation of Visually Impaired People

L'appareil consiste en une caméra grand public rouge, vert, bleu avec de la profondeur (RGB-D pour red, green, blue, depth) et une unité de mesure inertielle (IMU pour Inertial Measurement Unit), c'est un capteur qui consiste généralement en des gyroscopes pour mesurer des vitesses angulaires et des accéléromètres pour mesurer la force [1]. Ces appareils sont montés sur une paire de lunettes et reliés à un téléphone. L'appareil proposé dans cette solution se sert de la continuité de la hauteur du sol entre les images adjacentes pour segmenter le sol avec précision et rapidité pour ensuite chercher la direction du mouvement en fonction du sol. Un réseau de neurones à convolution (CNN pour Convolutional Neural Network) léger est utilisé pour la reconnaissance d'objets (PeelNet avec l'ensemble de données "MS COCO" contenant des images de dimensions 640 x 640). Son schéma de fonctionnement est présenté dans la figure 3. Il permet de récupérer des informations concernant les endroits aux alentours et l'orientation des objets environnants. Le schéma



de fonctionnement du système est présenté dans la Figure 4.




FIGURE 3 – Schéma présentant le fonctionnement du système de reconnaissance d'objets.

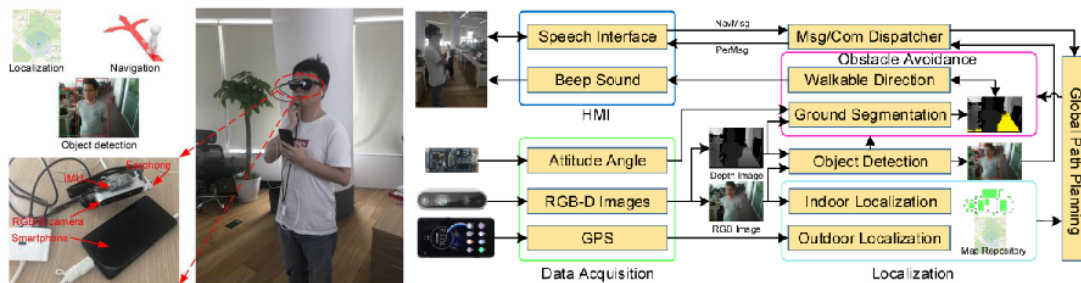


FIGURE 4 – Schéma de fonctionnement du système proposé.

Le système de navigation contient un module de localisation intérieur qui va nous intéresser : un algorithme VSLAM (Visual Simultaneous Localization and Mapping) est utilisé. SLAM est un problème de computer vision visant à traquer les mouvements d'un module en se basant sur ce qu'il voit. Il faut traiter les objets dynamiques qui entrent et sortent du champ de vision pour ne pas les prendre en compte dans l'estimation de la position du module. L'estimation se fait en trouvant des points clés sur les images successives. Visual SLAM se sert des informations récupérées pour trianguler la position 3D du module.

### 3.1.2 CDSFusion : Dense Semantic SLAM for Indoor Environment Using CPU Computing

La solution CDSFusion [6] se sert d'images RGB comme l'article précédent ainsi qu'un capteur IMU comme paramètres d'entrée et est composée de 3 modules imagés dans la Figure 5.

**3.1.2.1 Le module VIO** Le module d'odométrie visuelle-inertielle (VIO pour Visual-Inertial Odometry) se sert des entrées pour estimer avec précision la position afin de proposer une trajectoire. Ce module VIO est basé sur VINS-Mono. VINS-Mono est un framework SLAM en temps réel pour les systèmes visio-inertiels monoculaires. Il utilise une méthode de fenêtre glissante basée sur des optimisations pour fournir une odométrie visuelle-inertielle de haute précision. Les features FAST (Features from accelerated segment test) ont été adaptées pour accélérer le VIO à la place des feature Shi-Thomas (une manière de détecter les coins sur une image) et la profondeur a été introduite afin d'obtenir une échelle plus précise. Les résultats expérimentaux montrent que les features FAST augmentent la rapidité du système d'une manière plus conséquente que les features Shi-Tomas et ORB (Oriented FAST and Rotated BRIEF, expliqués en annexe) avec la même précision et robustesse. Ce module est composé de 3 parties :

Visual-Inertial Frontend : prend en charge le traitement des données issues des capteurs. Les mesures effectuées par le capteur IMU sont préintégréées entre deux images consécutives, le frontend de vision détecte les FAST et les traque entre les images consécutives en utilisant l'algorithme KLT (Kanade–Lucas–Tomasi) optical flow. KLT optical flow est un algorithme d'estimation du mouvement basé sur l'extraction de caractéristiques et utilise les informations d'intensité spatiale [4] [5].

Back-End : est utilisé pour fusionner les mesures traitées afin d'obtenir l'estimation de la position. Une optimisation non linéaire est utilisée pour relocaliser et optimiser le calcul de la position en fonction de la boucle détectée, en utilisant le solveur Ceres.

Le module de détection de boucle : permet de relocaliser et optimiser le calcul de la position en fonction de la boucle détectée. En effet, une boucle est détectée lorsque l'on a réalisé une boucle dans le parcours d'un chemin, il devient alors inutile de recalculer la position tant que l'utilisateur se situe dans cette boucle, on peut alors facilement optimiser le calcul de la position en se basant sur des calculs précédemment effectués. Cela se base sur la bibliothèque Dynamic Bag of Words (DBoW2) qui est à l'état de l'art de la reconnaissance d'endroits par sac de mots (bag of words approach). De même, lorsqu'une boucle est détectée, une optimisation est possible pour le calcul de la position globale. Cette optimisation est similaire à la méthode VINS-Mono.

**3.1.2.2 Le module de segmentation sémantique** La segmentation sémantique résulte d'images RGB en entrée qui sont acquises en temps réel en utilisant le module de segmentation PSPNet (Pyramid Scene Parsing Network) [7]. PSPNet est un module qui exploite le contexte global de l'information en regardant le contexte de régions de l'image puis agrège le tout. Les déductions locales accolées avec les déductions sur l'image globale produisent une prédiction finale plus fiable. Le module de segmentation sémantique traite

chaque image RGB et retourne des vecteurs indiquant la probabilité d'appartenance à une classe pour chaque pixel. Ils classifient et colorent chaque pixel en fonction de la plus haute probabilité d'appartenance à une classe. L'image segmentée finale est composée des pixels colorés et est transmise au module de reconstruction 3D.

**3.1.2.3 Le module de reconstruction 3D** Le nuage sémantique local est généré en utilisant une image sémantique (générée par le module précédent) et une carte de profondeur. Ce nuage local servira à produire un nuage global une fois qu'il sera combiné avec les estimations de position de la caméra depuis le module VIO. Pour construire une carte 3D globale qui soit précise, un modèle basé sur des voxels est utilisé pour filtrer le bruit et extraire un mesh global. À chaque image importante (Keyframe), la carte de profondeur courante est transformée en nuage de points 3D, ensuite les options Voxelbox et FAST sont adaptées, le nuage local de points 3D est transformé en mesh local et ensuite ce mesh local est intégré dans le mesh global. L'ensemble de cette procédure est réalisée en temps réel sur CPU. Voxelbox est une bibliothèque de cartographie volumétrique basée principalement sur les TSDF (Truncated Signed Distance Fields).

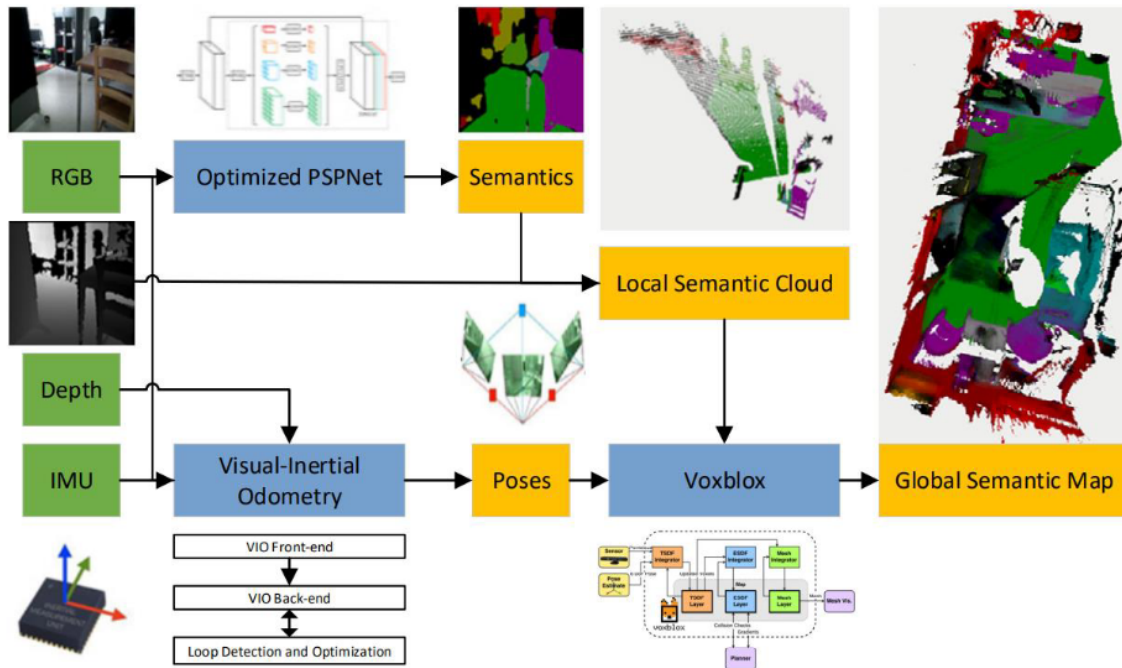


FIGURE 5 – Schéma présentant le fonctionnement du système proposé.

### 3.1.3 Towards Real-time Semantic RGB-D SLAM in Dynamic Environments

Cet article [3] présente une méthode de SLAM s'inspirant des features ORB. Le module de segmentation sémantique est une adaptation de SegNet, un réseau de neurones léger qui permet un traitement en temps réel. La segmentation se concentre sur des objets dynamiques dont les caractéristiques ne seront pas utilisées dans la création de la carte locale. La segmentation est faite uniquement sur les images clés les plus récentes, accélérant grandement le processus. La segmentation peut être très rapide, mais reconnaît principalement les objets qu'elle connaît déjà et est moins efficace dans des milieux inconnus avec des objets dynamiques nouveaux. Ce module essaye de résoudre ce problème. Pour chaque nouvelle image, l'idée est d'utiliser l'algorithme du K-means pour segmenter l'image de profondeur en N clusters. Chaque cluster est considéré comme faisant partie du même objet. Pour chaque cluster, une erreur de reprojection est calculée. Si une des erreurs moyennes est relativement supérieure aux autres, le cluster est considéré comme un objet dynamique et les points caractéristiques de l'objet seront supprimés du traitement. Cette manière de traiter les images permet de réduire le taux de faux positifs. Les comparaisons sont effectuées d'une image clé à une autre puisqu'elles se ressemblent beaucoup, mais aussi entre la première estimation et les cartes locales obtenues.

### 3.1.4 ORB-SLAM3 : An Accurate Open-Source Library for Visual, Visual-Inertial and Multi-Map SLAM

ORB-SLAM3 [2] est une amélioration d'ORB-SLAM2, présenté en Figure 6, qui consistait à travailler sur trois tâches simultanément : le suivi, la cartographie locale et la fermeture de boucle. Dans sa partie de suivi, ORB-SLAM2 fait correspondre les caractéristiques image par image et les compare avec une carte locale pour trouver l'emplacement exact de la caméra en temps réel. Il procède à un ajustement en fonction du mouvement afin de minimiser l'erreur de reprojection. Vient ensuite la partie cartographie locale dans laquelle ORB-SLAM2 crée des cartes locales et les optimise en utilisant des algorithmes tels que Iterative Closest Point (ICP) et effectue un ajustement local afin de calculer la position la plus probable de la caméra. Enfin, il utilise l'optimisation du graphe des positions pour corriger la dérive accumulée et effectuer une fermeture de boucle. Il est nécessaire d'effectuer un ajustement groupé après la fermeture de la boucle, afin que l'utilisateur se trouve à l'emplacement le plus probable dans la carte corrigée. Après l'ajout d'une image clé à la carte ou l'exécution d'une fermeture de boucle, ORB-SLAM2 peut démarrer un nouveau fil d'exécution qui effectue un ajustement de l'ensemble de la carte afin que l'emplacement de chaque image clé et des points dans celle-ci obtienne une valeur d'emplacement ajustée.

Pour traiter une image RGBD, on calcule d'abord dessus les caractéristiques ORB, ensuite depuis une paire d'images on estime les coordonnées de l'image de gauche. Un point est associé à "proche" ou "éloigné" en fonction de sa profondeur. Chaque dénomination a des caractéristiques utiles, un point proche sera représentatif pour le changement d'échelle, la translation, la rotation alors qu'un point éloigné sera surtout utile pour la rotation et devra être supporté par un plus grand nombre d'images. À l'initialisation, le système nécessite seulement les premières images clés pour estimer la première carte locale en utilisant les informations de profondeur. L'insertion d'une nouvelle image clé est importante, car elle définit le nouvel environnement sur lequel se base l'estimation du

mouvement de la caméra. Elle suit l'idée établie par la première version d'ORB-SLAM, d'insérer régulièrement de nouvelles images clés, même si cela implique de devoir les retirer si elles sont redondantes. L'ajout de points clés proches et éloignés permet un nouveau seuil d'apparaître pour déterminer si une nouvelle image clé est nécessaire. Si le nombre de points proches devient inférieur à un seuil, il sera nécessaire d'insérer une nouvelle image clé comportant au moins un certain nombre de points proches supérieur à un autre seuil.

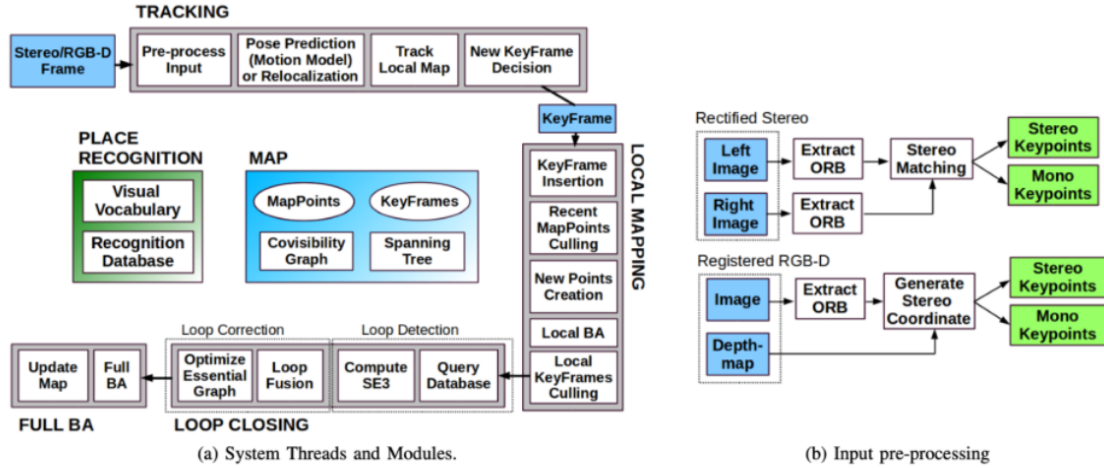


FIGURE 6 – Schéma présentant le fonctionnement d'ORB-SLAM2.

ORB-SLAM3 introduit l'utilisation de mémoire à court, moyen et long terme. En se servant des données que l'on a déjà vues, on peut retrouver facilement les boucles et ainsi réduire les erreurs de dérive. Une représentation en sac de mots dynamique (DBoW2) est utilisée. Ce système est présenté en Figure 7.

Le thread de tracking traite chaque nouvelle image afin de vérifier si elle représente une nouvelle image clé afin de la localiser dans la carte active de l'atlas. Si le tracking est perdu, le système essaye de se relocaliser en cherchant des repères visuels qu'il a déjà rencontrés par le passé. Si cela ne fonctionne pas, il créera une nouvelle carte qui sera la nouvelle carte active dans l'atlas. On dispose donc d'un atlas de cartes locales, un ensemble de cartes déconnectées qui seront peut-être combinées avec le temps grâce au système de fermeture de boucles.

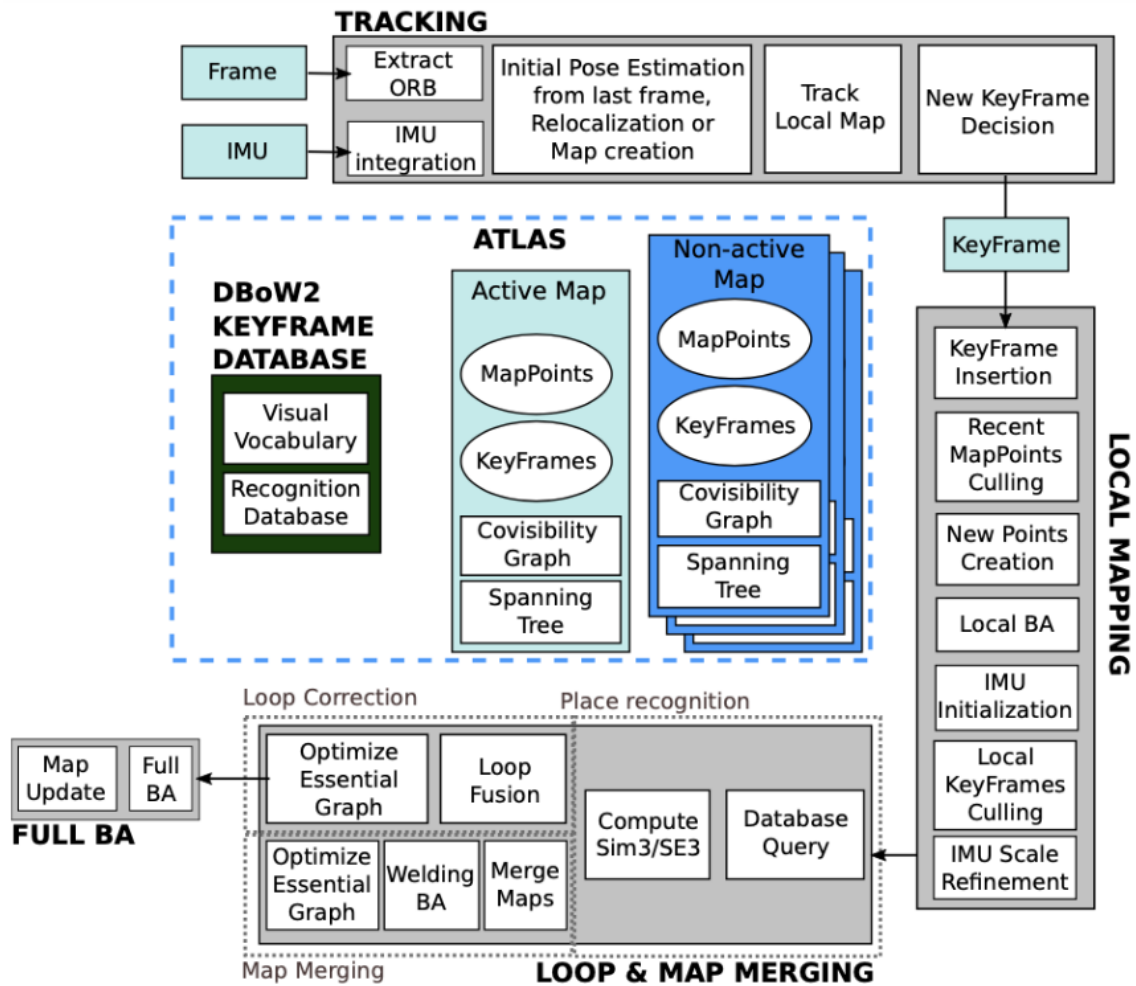


FIGURE 7 – Schéma présentant le fonctionnement d'ORB-SLAM3.

### 3.2 Synthèse

L'article "Wearable Travel Aid for Environment Perception and Navigation of Visually Impaired People" est très détaillé et demande beaucoup de temps pour saisir chaque subtilité. Au début de l'article, les auteurs listent les solutions qui existent déjà et expliquent leurs limitations respectives. Chaque partie de la solution est expliquée et peut être trouvée dans leurs travaux précédents. Cette solution prendrait beaucoup de temps à implémenter puisque les auteurs font surtout une description de leur travail sans mettre à disposition de code source. Il faudrait parcourir tous leurs travaux précédents pour comprendre l'intégralité de cette solution. De plus, il faudrait adapter les travaux proposés afin de créer la carte locale en temps réel plutôt qu'avant, puisque c'est une des contraintes imposées par nos superviseurs.

L'article "CDSFusion : Dense Semantic SLAM for Indoor Environment Using CPU Computing" est très prometteur, mais n'est pas assez détaillé pour nous permettre de reproduire cette solution à partir de rien. De plus, ils utilisent des capteurs IMU, que nous avons convenu de ne pas utiliser dans le cadre de ce projet.

L'article "Towards Real-time Semantic RGBD SLAM in Dynamic Environments" apporte une solution de tracking de la localisation d'un module en temps réel, ce qui correspond à ce que l'on recherche dans le cadre de ce projet. Cette solution aide à garder en mémoire les directions prises jusqu'à arriver à un point donné. Cependant les auteurs ne parlent que peu d'ORB-SLAM et se focalisent surtout sur leur valeur ajoutée permettant d'améliorer les résultats de ce dernier.

Enfin, l'article "ORB-SLAM3 : An Accurate Open-Source Library for Visual, Visual-Inertial and Multi-Map SLAM" semble être le plus abouti que nous ayons pu lire, il est à l'état de l'art et obtient de meilleures performances que ses concurrents. L'article est assez bien expliqué et fournit un code source disponible sur Github. Cette solution semble réutilisable pour notre problème, cela apporterait un bon moyen de traquer les mouvements d'une personne malvoyante dans une pièce. Certains aspects de la publication semblent compliqués à comprendre, mais la méthode en elle-même nous semble accessible. Il faudrait passer du temps sur leur code source afin de l'appréhender et se rendre compte de la faisabilité de sa mise en place.

### 3.3 Conclusion

Pour conclure sur cet état de l'art, nous avons découvert plusieurs méthodes permettant de traquer le mouvement d'une caméra dans un milieu intérieur, chacune avec son niveau de complexité et de faisabilité par rapport à nos contraintes qui étaient de n'utiliser aucun autre capteur qu'une caméra. Notre but était de fournir un module permettant de guider une personne d'un point A à un point B avec l'aide de notre module créant une carte locale de l'environnement, en nous basant sur des points et des lieux d'intérêt, s'emboîtant avec les modules de traitement du langage naturel, et le module de détection d'objets. L'article "ORB-SLAM3 : An Accurate Open-Source Library for Visual, Visual-Inertial and Multi-Map SLAM" nous a semblé être le plus pertinent pour arriver à notre but. En effet nous pourrions nous baser sur leur solution de tracking et construire par-dessus pour répondre au besoin fonctionnel de ce projet. De plus, le fait que les auteurs mettent à disposition leur code source donne une première vision de ce qui pourrait être réalisé en termes de performances avec notre propre environnement.



## 4 Les dimensions techniques du projet

### 4.1 Phase de preuve de concept

Le projet FYW vise à aider les personnes malvoyantes à se repérer en milieu intérieur. La preuve de concept (POC) sur laquelle j’ai travaillé avec mon équipe, se concentrait sur la création d’une carte locale de l’environnement, en nous basant sur des points d’intérêts (POI) entre les images vues successivement, c’est la méthode SLAM.

#### 4.1.1 Installation

Il a d’abord fallu se pencher sur l’installation de la solution que nous avons retenue, afin de construire notre module par-dessus. Nous avons été capables de produire une documentation d’installation de ORB-SLAM3 sur le Windows sub-system for Linux (WSL2) et sur une machine virtuelle (VM). Pour chaque module, nous avons vérifié qu’il pouvait bien s’installer avec les commandes d’acquisition de modules d’Ubuntu 20.04 (*sudo apt-get install ...*), puis nous avons ajouté ces commandes à notre script d’installation. Il a souvent été nécessaire de définir de nouvelles variables d’environnement afin que les modules que nous installons puissent fonctionner correctement. Cette création de variables d’environnement se faisait depuis le script d’installation qui écrivait dans le fichier *.bashrc* de notre système, fichier exécuté à chaque lancement du système. On a par exemple *echo "export WORKDIR='pwd'" >> ~/.bashrc*. Les bibliothèques de code utilisées décrites plus bas étaient installées avec *cmake*. Ces documentations d’installation appartiennent à Aubay et ne peuvent être divulguées dans ce document. Ensuite il a fallu calibrer la caméra que nous utilisons pour fonctionner avec ORB-SLAM3. La calibration de la caméra assure que l’estimation de la position de la caméra est la plus proche de la position réelle de la caméra. Enfin, l’idée était de développer un algorithme de recherche du plus court chemin entre deux points donnés, par exemple entre la position de l’utilisateur et une destination précédemment sauvegardée.

**4.1.1.1 General** Notre méthode se base sur ORB-SLAM3, une solution open source créée dans une université en Espagne. L’idée était simple, nous voulions l’installer et la faire fonctionner puis ajouter les fonctionnalités nécessaires à notre POC. Ce projet open source a été développé en C++ et se base sur de nombreuses bibliothèques de code telles que Eigen, Pangolin, Sophus, DBoW2, g2o, Kalibr et ROS. Avant d’installer ORB-SLAM3, nous avons dû installer Eigen et Pangolin. Sophus, DBoW2 et g2o étant déjà inclus dans leur dépôt Github.

Nous avons essayé d’installer ORB-SLAM3 sur Windows 10, Mac OSX, Ubuntu 20.04 sur VirtualBox et enfin WSL2. L’installation sous Windows 10 a rapidement été déclarée impossible puisqu’ORB-SLAM3 a été développé pour un système Linux en grande majorité. L’installation sur Mac OSX n’a été que temporaire, le temps que l’on obtienne l’autorisation de travailler avec WSL2. Nous avons donc réalisé l’installation d’ORB-SLAM3 sur WSL2 et réussi à lancer le SLAM sur la vidéo d’exemple fournie. Cependant notre POC devait fonctionner avec un flux vidéo en temps réel provenant d’une caméra, et non une vidéo préenregistrée. Le problème était que bien que wsl2 ait accès aux appareils USB (en prenant en compte que pour cela il était nécessaire de créer un nouveau noyau Linux contenant

les bons pilotes) et que la caméra soit visible dans les pilotes USB, le sous-système n'était pas capable de créer la vidéo dans `/dev/video`, rendant le flux vidéo inaccessible à notre application. Nous avons choisi de basculer sur un système Ubuntu 20.04 sur VM afin de disposer des fonctionnalités de base nécessaires à notre avancée.

**4.1.1.2 Eigen** Eigen est une bibliothèque d'algèbre linéaire, elle traite les vecteurs, matrices, solveurs numériques et les algorithmes associés. Cette bibliothèque est nécessaire au bon fonctionnement d'ORB-SLAM3. Pour l'installer, nous avons dû chercher la version adaptée puisque la bibliothèque a évolué depuis la publication du dépôt Github d'ORB-SLAM3, rendant les versions les plus récentes de Eigen incompatible avec le projet. Nous avons essayé plusieurs versions qui n'ont pas fonctionné jusqu'à déterminer que la version 3.3.1 était la version utilisée au moment du développement d'ORB-SLAM3.

**4.1.1.3 Pangolin** Pangolin est un ensemble de bibliothèques utilitaires légères traitant de prototypage 3D et d'algorithmes numériques ou basés sur de la vidéo. Elles sont utilisées pour s'affranchir des contraintes d'environnement et rendre facile la visualisation des données. Pour l'installation, de même que pour Eigen, la version la plus récente ne correspondait pas, alors il a fallu chercher dans l'historique des versions et tester jusqu'à trouver la version 0.6 sur leur Github qui nous a permis de lancer le projet.

**4.1.1.4 ORB-SLAM3** Pour installer ORB-SLAM3, il a d'abord fallu cloner le dépôt Github de la version 1.0. Il y avait des prérequis qui ne correspondaient pas à notre environnement, tels que la version d'OpenCV qu'il a fallu adapter, nous avons déterminé que la version 4.2 était la bonne. Pour chaque bibliothèque nécessaire, nous avons dû trouver la version adaptée à notre projet. Ensuite nous avons pu installer les bibliothèques tierces déjà contenues dans le dossier du projet.

**4.1.1.5 ROS** Robot Operation System (ROS) est utile au moment de l'accès à la caméra par ORB-SLAM3 pour traiter le flux vidéo. Ce package censé être rapide à installer nous a posés beaucoup de soucis de packages cassés dans les dépôts en ligne. Nous avons essayé diverses solutions sans succès sur la VM, pour finalement réussir à faire fonctionner le tout sur WSL2.

## 4.1.2 Calibration

Comme dit précédemment, la calibration de la caméra était une phase importante afin d'obtenir une bonne estimation de la position de la caméra utilisée. En effet, les paramètres intrinsèques et les distorsions de la caméra sont ce qui définit la manière dont un objet dans le monde réel va être projeté dans l'espace image. C'est la première étape nécessaire à l'obtention d'une méthode de SLAM performante. Ces paramètres varient d'une marque à une autre, mais aussi entre les différents modèles d'une même marque.

Ros et Kalibr sont deux packages qui permettent d'effectuer une calibration. Le premier est pratique à utiliser puisqu'il donne un retour instantané sur la calibration et indique quand celle-ci est finalisée. Le second est moins visuel, mais c'est le module conseillé par les développeurs d'ORB-SLAM3.

Le processus de calibration est le même pour chaque package. Le principe est d'utiliser un modèle de dimension connue comme un plateau d'échec contenant des cases blanches et noires de taille fixe. L'idée est donc d'estimer la déformation de la caméra sur ces dimensions connues en montrant plusieurs plans de vue du plateau à la caméra.




FIGURE 8 – Exemple de calibration.

#### 4.1.3 Recherche de chemin

Après avoir passé un certain temps sur le code source d'ORB-SLAM3 pour comprendre comment chaque partie fonctionnait, nous avons été en capacité de réfléchir à comment nous implanter dedans pour ajouter notre contribution. L'idée était d'être capable de garder en mémoire les lieux importants pour l'utilisateur (POI) et de lui permettre d'y retourner en trouvant le chemin le plus court entre la position courante et la destination voulue grâce à l'algorithme A\*.

**4.1.3.1 Matrice de coordonnées** Les coordonnées résultantes d'ORB-SLAM3 sont des nombres flottants généralement compris dans l'intervalle  $[0, 1]$  pour les vidéos courtes. Nous avons besoin d'un moyen de projeter ces coordonnées sur une grille afin de déterminer le chemin à parcourir et donner des indications de direction, il a alors fallu adapter le résultat fourni par ORB-SLAM3.

La projection est assez simple, nous multiplions la coordonnée flottante de la caméra par 10, on arrondit au supérieur afin d'obtenir un nombre entier puis on divise le résultat par 10. Cela nous a permis d'obtenir une grille de coordonnées discrétisées qui ne soit pas trop petite (une grille trop petite correspondrait à des espacements plus petits qu'un pas dans le monde réel), ce qui nous permet de ne pas guider l'utilisateur trop souvent. Un exemple de cette méthode de discrétisation est présenté dans la Figure 9.

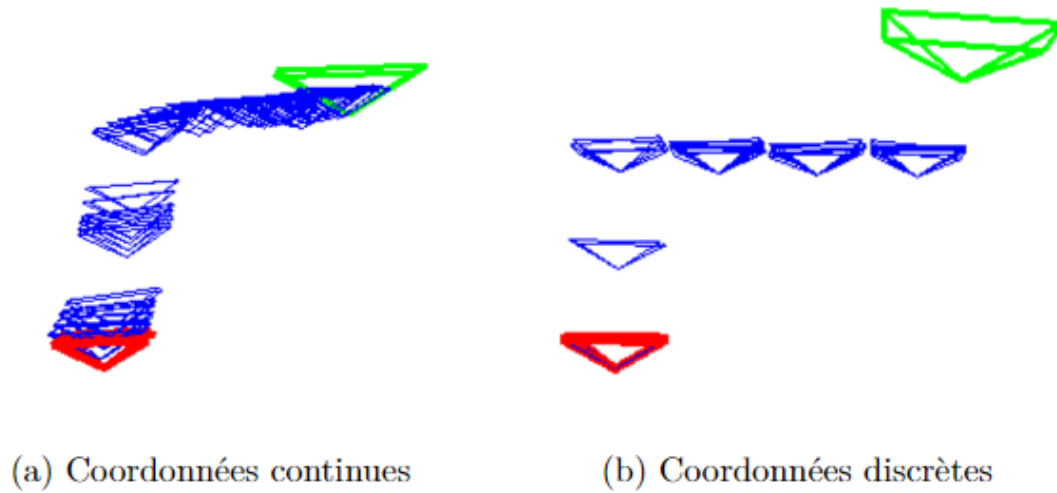


FIGURE 9 – Exemple de discrétisation.

### 4.1.3.2 Structures de données définies

**4.1.3.2.1 Coord** Nous avons créé une structure *Coord* en C++, équivalente à un vecteur 2D. Cette structure est utilisée par tous nos algorithmes.

**4.1.3.2.2 AbsoluteCoord** Les coordonnées absolues sont les coordonnées de la caméra qui ont été projetées sur une grille discrète. Nous avons créé une structure *AbsoluteCoord* contenant 5 champs :

- *int*  $x_{min}, x_{max}, y_{min}, y_{max}$  : les dimensions de la grille.
- *vector<Coord>* *coords* : Le chemin parcouru par la caméra.

**4.1.3.2.3 Path** Nous avons créé une structure *Path* contenant 2 champs :

- *Coord start* : la position courante sur la carte quand le chemin est sauvegardé, celle qui sera fournie à l'algorithme A\* pour la recherche de chemin.
- *vector<vector <int >> Map2D* : La matrice représentant les chemins explorés par l'utilisateur. Cette carte 2D est créée depuis les coordonnées absolues.

**4.1.3.2.4 PoiList** Nous enregistrons la liste des POI sauvegardés sous la forme d'un dictionnaire *map<string, Coord> poiList* qui associe un nom à une position. Ce dictionnaire est mis à jour lorsque l'utilisateur demande la sauvegarde d'un endroit.

**4.1.3.3 L'algorithme A\*** L'algorithme A\* est un algorithme de recherche dont le but est de trouver le plus court chemin entre 2 positions dans une matrice. Imaginons une grille carrée contenant des obstacles répartis aléatoirement, on fournit la position de départ *A* et la destination *B*. Le but est de rejoindre la destination le plus rapidement possible. L'algorithme A\* prend 3 paramètres :

- *G* : Le coût de déplacement de la cellule initiale jusqu'à la cellule courante. Cela correspond à la somme de toutes les cellules qui ont été visitées depuis le départ de la première cellule.
- *H* : La valeur heuristique, c'est une estimation du coût de déplacement depuis la cellule courante jusqu'à la destination. Il faut faire attention à ne pas surestimer cette valeur.
- $F = G + H$

A\* base sa décision sur la valeur de *F*, il cherche toujours à minimiser cette valeur jusqu'à atteindre sa destination, comme le montre la Figure 10. On observe la décision prise par l'algorithme pour rejoindre le point bleu à partir du point rouge, alors qu'ils sont séparés par un obstacle, rendant le chemin en ligne droite impossible.




FIGURE 10 – Exemple de A\*.

**4.1.3.4 Retourner à un point d'intérêt** Dans cette partie nous avons ajouté un bouton à l'interface graphique fournie avec ORB-SLAM3 qui affiche la liste des POI et demande à l'utilisateur de choisir sa destination. La coordonnée associée à la destination choisie est donnée à A\* pour trouver le plus court chemin praticable. Le chemin trouvé est ensuite donné à la fonction *FYWBack()*.

**4.1.3.5 FYWBack** Après avoir récupéré la sortie de l'algorithme A\* sous la forme d'une liste de coordonnées, *FYWBack()* fournit des indications de directions en se basant sur la normale sur le plan de la caméra et calcule l'angle avec la section de chemin la plus proche afin de guider l'utilisateur. Le chemin à parcourir est régénéré section par section.




FIGURE 11 – Grille 2D de la carte locale.





FIGURE 12 – Normales des images clés en temps réel.



```
Please name the POI
first
POI List:
{first: (0, 2) }
Tracking: Waiting to the next step
Please name the POI
second
POI List:
{first: (0, 2) }
{second: (1, 2) }
```

FIGURE 13 – Sauvegarde d'un point d'intérêt.

```
Welcome to the Pathback() function !
POI List:
{first: (0, 2) }
{second: (1, 2) }
Which POI do you want to reach ?
first
You are being directed toward (0, 2)
Found a path
You need to use this path
(1, 2)
(0, 2)
```

FIGURE 14 – Retour à un point d'intérêt.

#### 4.1.4 Test et résultats

Nous avons testé notre travail sur plusieurs vidéos prises dans l'open space. Nous avons d'abord essayé de créer une grille 2D de la carte locale et de positionner les coordonnées discrétisées dessus, comme présenté dans la Figure 11, puis nous avons calculé les normales des images clés en temps réel comme présenté dans la Figure 12. Nous avons ensuite réussi à sauvegarder une position, appelée POI, et la nommer comme présenté en Figure 13. Enfin nous avons créé une fonction de retour à un POI depuis la position courante, montrée dans la Figure 14.

#### 4.1.5 Difficultés rencontrées

Nous avons passé la majeure partie du temps que nous avions à disposition pour le POC à essayer d'installer ORB-SLAM3. La recherche des bonnes versions pour chaque bibliothèque nous a beaucoup retardé. Nous avons dû éditer certaines parties du code source, notamment au niveau de CMakeLists.txt pour faire fonctionner le tout. De nombreux problèmes sont survenus concernant quasiment chaque package que nous devions installer, la plupart du temps à cause de problèmes de compatibilité ou de documentation manquante. La seule solution que nous ayons trouvée a été de chercher sans relâche jusqu'à trouver une solution. Lorsque nous travaillions sur la VM, des latences et des crashes inattendus nous ont également fortement ralenti.

#### 4.1.6 Conclusion

Pour conclure sur la phase de POC, nous avons réussi à faire fonctionner un système SLAM pour la première fois chez Aubay, d'autres équipes ayant essayé sans succès par le passé. En plus de réussir l'installation, nous avons ajouté les fonctionnalités nécessaires pour atteindre notre but et avoir un module prêt à intégrer la phase projet pour venir se lier aux autres POCs de notre projet.

### 4.2 Phase projet

Une fois la phase de POC terminée, nous devions passer à la phase projet associant nos POCs afin de créer une application de démonstration pour la JDS du 7 juillet 2022. Cette journée est un jalon très important pour tout stagiaire au sein de la cellule Innov' de chez Aubay. Elle sert à présenter le projet sur lequel chaque équipe a travaillé, afin de montrer à la direction générale ainsi qu'aux directeurs commerciaux, ce dont les stagiaires sont capables et ce qu'Aubay pourrait proposer à ses clients dans le futur. Nous avons donc réfléchi à la création d'une application et d'une interface graphique afin de démontrer le fonctionnement de notre application, bien que l'application finale soit destinée à des personnes malvoyantes, ne nécessitant qu'une interface vocale.

#### 4.2.1 Protocole de communication

Il est important de noter que nos 3 POCs ne fonctionnent pas sur les mêmes systèmes, en effet, le POC SLAM développé en C++ fonctionne uniquement sur WSL2, tandis que les POCs Computer Vision (CV) et Natural Language Processing (NLP) sont développés en Python sur Windows. Le problème étant que WSL2 ne nous permettait pas d'accéder au flux vidéo de la caméra nécessaire aux POCs SLAM et CV, alors qu'une VM nous le permettait, mais ne donnait pas accès aux unités de traitement graphiques (GPU) nécessaires aux POCs CV et NLP. Nous avons opté pour trouver une solution concernant le problème de flux vidéo sur WSL2. Étant donné que les 3 POCs devaient fonctionner sur le même réseau local, nous avons eu l'idée de mettre en place un serveur afin d'établir une communication entre Windows et WSL2 pour transmettre le flux vidéo de Windows à WSL2. Cette solution a nécessité d'adapter la manière dont ORB-SLAM3 récupérait le flux vidéo avant de l'incorporer à son fonctionnement normal.



L'application est composée d'un backend se chargeant des fonctionnalités tandis que le frontend s'occupe du rendu graphique afin de présenter les résultats à l'utilisateur. La structure de l'application est simple : Les 3 POCs communiquent à un chef d'orchestre pour envoyer leur requête ou récupérer le résultat d'une requête précédemment effectuée et le frontend récupère les résultats à afficher après avoir sélectionné le mode de démonstration adapté. Ce fonctionnement est illustré dans la Figure 15. C'est l'interface (en rouge) qui permet de lancer l'application et d'afficher les résultats. Une fois l'application lancée par l'interface, la communication entre le chef d'orchestre (Commander) et les différents modules est établie grâce à un serveur Flask.

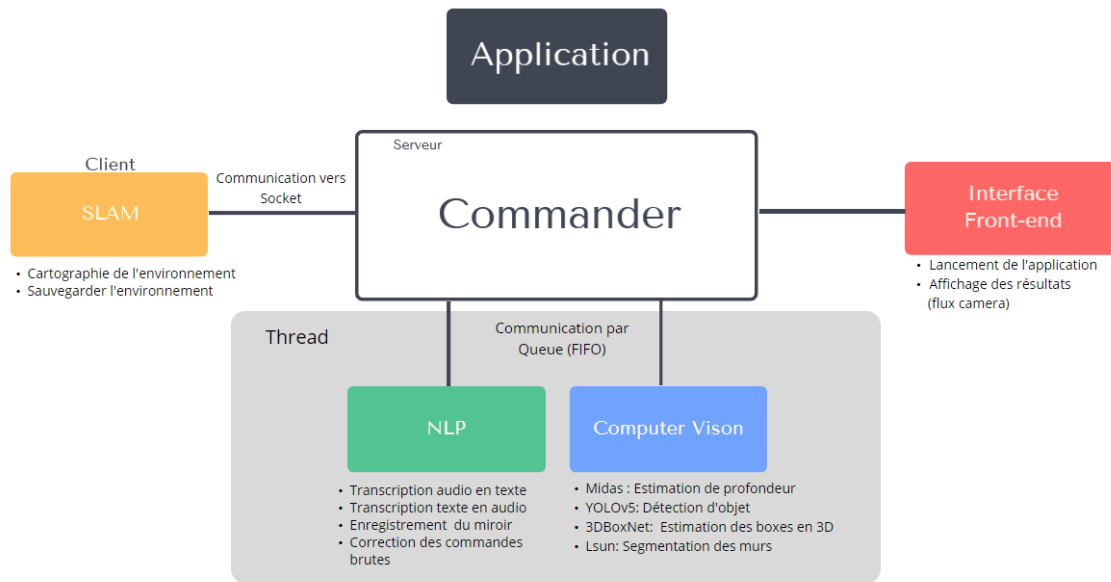


FIGURE 15 – Schéma présentant l'architecture de l'application.

Le POC SLAM se situe sur un système différent et utilise un langage de programmation différent des POCs CV et NLP, nous avons dû recourir aux sockets qui sont disponibles dans beaucoup de langages de programmation dont C++ et Python. Après avoir autorisé les communications au niveau du proxy et du par-feu en ouvrant les bons ports. Une fois cette communication rendue possible, nous avons ajouté des threads au code d'ORB-SLAM3 pour permettre des interruptions pour envoyer les données nécessaires après leur traitement ou recevoir les instructions du chef d'orchestre afin d'exécuter les fonctions utiles au bon moment. Un schéma global des communications établies au sein du projet est disponible en annexes 21 et 22.

Une socket est un port ouvert sur une machine afin de recevoir ou d'envoyer de la donnée à d'autres ordinateurs sur un même réseau. Ce point d'entrée permet de gérer plusieurs types de protocoles de communication, dont le transfert de fichiers locaux et de données qui nous intéressent ici. Dans la pratique, il faut toujours s'assurer que la socket est bien valide, que le port n'est pas déjà utilisé, que le port n'est pas endommagé à la suite d'une fermeture brutale. Il fallait également spécifier la taille de la donnée que l'on voulait envoyer, ici on mesurait simplement la taille de la chaîne de caractère à envoyer.

Un thread quant à lui est un processus qui permet d'exécuter des instructions de langage machine au sein du processeur. Ce processus un peu spécial permet à deux instances d'un même programme de s'exécuter en "simultané" (pas exactement en même temps, mais à l'échelle de cette explication nous pouvons considérer que les deux processus s'exécutent en simultané sans que cela n'altère la compréhension du lecteur) au sein d'un même processeur. Dans la pratique, cela nous a permis de lancer le programme principal, pour qu'il exécute ses tâches, et lorsque cela était nécessaire (notamment lors d'une interaction avec l'utilisateur), d'envoyer les données nécessaires à l'interface via le serveur Flask et les sockets, sans que cela ne bloque le programme. Ceci n'aurait pas été possible sans l'utilisation de threads.

#### 4.2.2 Développement de l'application

Aubay nous a proposé de choisir entre Angular et Flutter comme framework de développement, avec une préférence pour Flutter qui était une technologie encore inconnue de l'entreprise. Ayant déjà travaillé avec Flutter sur un petit projet personnel, j'ai orienté le développement sur ce framework. L'idée était de créer une page d'accueil contenant des boutons appelant les fonctionnalités de l'application. Nous devions donc être capables d'exécuter des scripts Python, afin de communiquer avec les composants de l'application, et de pouvoir recevoir des images à afficher pour constituer la vidéo de retour, en notant qu'une succession d'images affichées rapidement constitue une vidéo.

Flutter s'est avéré être très pratique à utiliser et à prendre en main, avec l'avantage de produire des pages sans avoir à se préoccuper des graphismes qui étaient déjà pris en charge. Cependant un certain nombre de problèmes sont survenus lorsque nous avons voulu récupérer des images depuis un serveur et les afficher en temps réel. En effet la récupération et la conversion au format adéquat pouvaient être lentes et ne pas permettre un affichage en temps réel. De plus l'exécution de scripts Python était une option assez limitée du framework que nous n'avions pas envisagée au moment de le choisir pour développer l'application. Nous nous sommes en fait rendu compte des limites de Flutter pendant que nous essayions de l'employer pour développer notre application de démonstration. À la vue des multiples problèmes engendrés par ce dernier, nous avons choisi de l'abandonner au profit d'une solution connue.

Nous avons recommencé le développement avec Python en utilisant le package PyQt5, un module de création de fenêtres graphiques. Les pages générées demandent un minimum de travail au niveau des graphismes pour donner un résultat satisfaisant pour la démonstration. Avec ce package, il nous était désormais facile d'appeler des scripts Python et de communiquer avec les autres parties du projet. Il a donc été assez rapide de reproduire les pages que nous avions déjà créées avec Flutter.

L'astuce a été de trouver comment afficher une vidéo récupérée image par image dans l'application. Après quelques tests et réflexions, il s'est trouvé qu'il fallait simplement procéder à l'affichage en continu d'une image récupérée avec le serveur Flask, et que l'image la plus récente remplace l'affichage courant, ce qui nous donne une vidéo de résultat.

L'application fonctionne avec une caméra, un microphone et un haut-parleur. L'interface graphique donne la possibilité de lancer une démonstration et de démarrer les parties SLAM, CV et NLP via le serveur Flask et des sockets. La page principale de l'application est montrée en Figure 16, on y voit les résultats des POCs CV et SLAM ainsi que les différents boutons permettant à l'utilisateur d'interagir pour tester l'application :

"Vidéo démo" permet de lancer une vidéo de démonstration préenregistrée dans l'open space en cas de problème lors de l'accès à l'ordinateur à distance lors de la JDS.

"Temps réel" est le bouton qui envoie le signal de départ au chef d'orchestre pour lancer tous les POCs. Quand ce bouton est pressé, les scripts Python lançant le serveur Flask, le POC SLAM, CV et NLP, sont appelés. La caméra s'allume et le flux vidéo est transmis aux POCs SLAM et CV pour commencer leur traitement. SLAM envoie ses images résultantes par socket au serveur Flask qui fait le pont avec l'interface graphique, c'est l'image en bas à droite de l'application. En parallèle, CV détecte les obstacles et objets environnants en estimant leur distance à l'utilisateur. Ces détections sur le flux de la caméra sont montrées à l'utilisateur sur la partie centrale de l'application. CV fournit aussi une carte 2D des obstacles détectés, c'est la carte en haut à droite de l'application.

"Microphone" ouvre une interface demandant de prononcer une commande pour interagir avec l'application qui fonctionne en temps réel. L'utilisateur peut prononcer des commandes telles que "Emmène-moi à un objet", ce à quoi l'application répondra à l'oral "Lequel?", l'utilisateur devra prononcer le nom de l'objet, par exemple : "bouteille", "chaise" ou encore "porte", puis il se fera guider grâce au module CV quand ce dernier aura détecté l'objet recherché dans le champ de vision de la caméra. Une autre commande possible est de demander la sauvegarde d'une position, via le module SLAM, en prononçant "Sauvegarde une position", ce à quoi l'application répond "Laquelle?" afin de nommer ce lieu et de pouvoir s'y faire guider par le module SLAM plus tard. La liste exhaustive des commandes vocales possibles est présentée dans la Table 1. Ces commandes provoquent des "interruptions" (gérées par les threads afin de ne pas perturber l'exécution normale de ces programmes) dans les POCs afin de récupérer les informations nécessaires à l'affichage graphique.

Commande	Réponse
Décris-moi les alentours"	"Les objets les plus proches sont [liste objets]"
"Emmène-moi à un objet"	"Lequel?"
"(nom de l'objet)"	"(objet) trouvé"
"Sauvegarde une position"	"Laquelle?"
"(nom de la position)"	"(nom de la position) enregistré"
"Liste les positions enregistrées"	"Vos lieux favoris sont : [liste des positions]"
"Guide moi vers une position"	"Laquelle?"
"(nom de la position)"	Début du guidage

TABLE 1 – Liste des commandes vocales disponibles.

Il est également possible de faire appel aux fonctions de SLAM à l'écrit et au clic par les boutons "Sauvegarder une position" et "Retourner à une position". Le premier bouton

demande une saisie à l'écrit pour enregistrer le nom de la position, tandis que le deuxième bouton affiche la liste des lieux sauvegardés que l'utilisateur peut sélectionner pour s'y faire guider.

"Historique" affiche l'historique des commandes vocales passées et des réponses reçues, ainsi que les lieux enregistrés et des lieux qui ont été demandés par l'utilisateur pour se faire guider, par le biais des boutons prévu à ces effets.

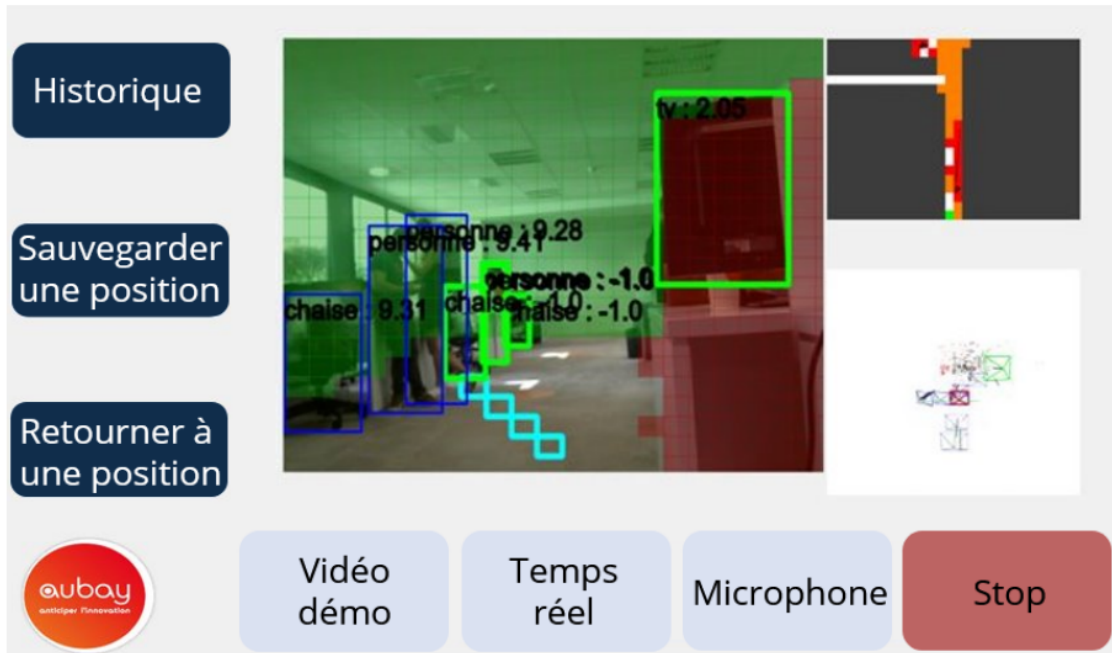


FIGURE 16 – Page principale de l'application.

#### 4.2.3 Conclusion

Pour conclure sur la phase projet, nous avons travaillé ensemble sur la construction d'une application complète liant nos POCs afin de fournir une démonstration le jour de la JDS. Cette journée s'est parfaitement déroulée et nous avons pu échanger avec différentes personnes de la direction d'Aubay ainsi que des directeurs commerciaux pour leur expliquer le fonctionnement de notre application. Nous avons appris à faire communiquer nos applications grâce à Flask et les sockets en établissant un protocole de communication.

## 5 Les dimensions humaines et managériales

### 5.1 Le plan humain

Le côté humain chez Aubay est beaucoup mis en avant. Dans le cadre de ce projet, cet aspect s’est matérialisé sous la forme d’un open space dans lequel plusieurs équipes travaillant sur des projets différents, ce qui permettait sur les temps de pause de créer du lien autour des différents endroits sociaux tels que la machine à café, la cafétéria ou encore le baby-foot. La crise sanitaire a empêché l’organisation d’événements pendant un certain temps, et c’est justement au moment de ce stage qu’Aubay a pu recommencer à organiser des événements de rencontres après les heures de travail. Ces événements ont grandement participé au côté humain tel que j’ai pu le vivre durant cette expérience.

Nous étions assez proches de nos encadrants et pouvions leur parler librement, leurs bureaux étant très proches de l’open space dans lequel nous travaillions. Nous pouvions aussi les contacter sur teams ou par mail, mais la plupart de nos échanges se faisaient de vive voix.

### 5.2 Le plan managérial

Chez Aubay les projets sont réalisés avec une méthode agile afin de fixer les objectifs et vérifier que nous les avons bien atteints de manière régulière. Ainsi nous participions chaque matin à un Daily, une réunion composée de l’équipe de stagiaires et de l’encadrant technique si besoin, visant à remonter les points bloquants que nous rencontrions ainsi que d’échanger sur l’avancée du projet. Le travail était organisé en sprints de 2 semaines pendant lesquels nous devions résoudre les tickets correspondant aux tâches à accomplir que nous nous étions fixées. Chaque semaine un scrum master était choisi parmi les membres de l’équipe afin qu’il anime les Daily. Un comité était organisé chaque mardi à 14h45 pour faire le point sur les avancées de la semaine passée et les objectifs encore à atteindre durant la fin du sprint. C’est aussi lors de ces réunions que nous pouvions être amenés à montrer des démonstrations à nos encadrants.

Pendant les sprints, les membres de l’équipe travaillaient en 3 groupes, un groupe par POC pour avancer sur leur partie du projet. Ces 3 groupes n’interagissaient professionnellement qu’au moment des Daily et des comités. C’est au moment de la phase projet que les groupes ont été remaniés en fonction des affinités de chacun sur les tâches à effectuer.

Concernant nos encadrants, nous avions un encadrant présent pour répondre à nos questions techniques si nous en avions et un encadrant agile qui s’assurait que le suivi du projet était réalisé de la bonne manière. C’est pendant les comités que nous regardions tous ensemble le Jira du projet pour nous rendre compte de l’avancée du projet, si nous documentions bien les tâches à effectuer afin que par la suite, il soit facile de reprendre le projet et de comprendre ce qui a été réalisé et pour quelles raisons.

Les personnes se portant volontaires pour être encadrants techniques sont généralement des personnes en intercontrat, attendant de trouver une mission les intéressant chez un client. C'est pourquoi il est arrivé à deux reprises que notre encadrant technique change. Heureusement, Aubay a correctement géré ce changement en organisant une réunion de passation durant laquelle le futur encadrant était mis au courant de l'état courant du projet qu'il devait désormais superviser.

Il nous est arrivé à de nombreuses reprises d'avoir des problèmes techniques pendant le projet, cependant nous avons pu recevoir de l'aide sous forme de pistes et d'indications afin d'essayer des options que nous n'avions pas envisagées.

## 6 Conclusion

### 6.1 Le bilan technique

Pour la première fois chez Aubay, un système de SLAM a été fonctionnel. J’ai eu la chance de travailler sur la base d’un projet open source, laissant entrevoir une technologie à la pointe de l’état de l’art, sur laquelle j’ai pu contribuer et la mettre en place dans un projet concret au travers de la phase de POCs et de la phase projet. J’ai beaucoup appris sur le sujet de la vision par ordinateur, les mathématiques associées à ces domaines techniques ainsi que les problématiques liées au traitement de l’image en temps réel.

J’ai renforcé mes connaissances sur la création de scripts shell sur Linux afin d’automatiser l’installation d’un ensemble de fichiers nécessaires au lancement d’un projet, mais aussi sur le débbugage d’erreurs d’installations multiples.

J’ai pu participer à la réalisation d’un protocole de communication entre plusieurs applications sur le même réseau local, me sensibilisant sur les problématiques liées aux sockets et aux serveurs de manière plus générale. Cela nous a permis de nous affranchir des différences de système d’exploitation et de langages de programmation.

J’ai également développé une application graphique pour la première fois, ce qui m’a beaucoup appris sur des frameworks de développement d’applications tels que Flutter et PyQt5, ce développement m’a beaucoup appris sur les notions liées à la communication entre l’affichage graphique et les fonctions sous-jacentes d’une application web ou bureau.

Cette expérience est venue compléter les compétences en développement que j’ai pu acquérir lors de mon cursus à l’ESIEA. En effet, c’est lors de divers projets d’école que j’ai appris le développement en C++ et Python qui m’ont servi lors de cette mission de fin d’études.

### 6.2 Le bilan humain

Humainement parlant, j’ai beaucoup apprécié travailler sur cette mission avec cette équipe au sein de l’open space des stagiaires. Cela m’a permis de me rendre compte des différences et des similarités dans les formations proposées par les autres écoles. J’ai eu des échanges très riches avec mes collègues stagiaires directs et aussi avec les stagiaires travaillant sur d’autres projets, notamment le jour de la JDS. J’ai amélioré et développé mes compétences humaines, vu la taille de mon équipe, il fallait être capable d’écouter le point de vue des autres, mais aussi de réussir à s’exprimer parmi la quantité de personnalités différentes que j’ai pu rencontrer.

### 6.3 Possibilités d'évolution du projet

Concernant les possibilités d'évolution du projet, d'autres méthodes de localisation pourraient être envisagées ou venir compléter la nôtre (comme la publication parlant de DGS avec le SegNet qui enlève les objets dynamiques du traitement). Le module SLAM pourrait être développé sur Windows également, mais cela prendrait un temps considérable. En se basant sur ce que nous avons produit, une possibilité d'évolution serait d'utiliser une caméra d'une meilleure qualité, possiblement une caméra grand-angle.

### 6.4 Perspectives d'évolution professionnelles

Pendant ce stage j'ai développé des compétences dans le domaine Agile et DevOps, notamment au niveau du suivi de projet avec Jira, du versionning avec Git, mais aussi en développement puisque j'ai pu renforcer mes compétences en C++ et Python. J'ai également eu une première approche du développement fullstack étant donné que j'ai pu participer à la création d'une application où il fallait gérer un affichage graphique en plus des fonctions contenues dans le back. Lors de mes études, j'ai surtout eu l'occasion de développer des fonctions en back, alors cette nouveauté du stage est venue compléter mon expérience pour me donner un point de vue neuf sur les différents métiers possibles autour de la programmation. J'ai également amélioré ma capacité de synthèse en lisant des articles scientifiques très techniques et en les résumant.

Le projet m'a permis de prendre conscience que j'aimais beaucoup le développement, en plus de ma forte appétence pour la data et l'intelligence artificielle. Les différentes rencontres que j'ai pu faire au cours du projet, les discussions avec des personnes déjà en CDI, m'ont fait comprendre que je manquais encore de certaines compétences techniques avant de pouvoir atteindre les postes que je vise. Le but va être de me former et de monter en compétences dans le domaine du Cloud (AWS) qui devient nécessaire dans énormément d'entreprises. En effet, le Cloud donne la possibilité de déployer des architectures matérielles ou des applications concrètes de la donnée à grande échelle, ce qui en fait un très bon complément des compétences en science des données. Cela donne également une belle perspective d'apprentissage continue en accord avec ma formation d'ingénieur, qui veut faire de nous des personnes curieuses, toujours prêtes à apprendre de nouveaux concepts intéressants et évoluer avec la technologie.



## 7 Bibliographie

1. Jinqiang BAI et al. « Wearable Travel Aid for Environment Perception and Navigation of Visually Impaired People ». In : *Electronics* 8.6 (juin 2019), p. 697. DOI : [10.3390/electronics8060697](https://doi.org/10.3390/electronics8060697).
2. Carlos CAMPOS et al. « ORB-SLAM3 : An Accurate Open-Source Library for Visual, Visual-Inertial, and Multimap SLAM ». In : *IEEE Transactions on Robotics* 37.6 (déc. 2021), p. 1874-1890. DOI : [10.1109/TR0.2021.3075644](https://doi.org/10.1109/TR0.2021.3075644).
3. Tete JI, Chen WANG et Lihua XIE. « Towards Real-time Semantic RGB-D SLAM in Dynamic Environments ». In : *2021 IEEE International Conference on Robotics and Automation (ICRA)*. Mai 2021, p. 11175-11181. DOI : [10.1109/ICRA48506.2021.9561743](https://doi.org/10.1109/ICRA48506.2021.9561743). arXiv : [2104.01316](https://arxiv.org/abs/2104.01316) [cs].
4. Bruce D LUCAS et Takeo KANADE. « An Iterative Image Registration Technique with an Application to Stereo Vision ». In : (), p. 10.
5. Jae Kyu SUHR. « Kanade-Lucas-Tomasi (KLT) Feature Tracker ». In : *Computer Vision* (2009), p. 37.
6. Sheng WANG et al. « CDSFusion : Dense Semantic SLAM for Indoor Environment Using CPU Computing ». In : *Remote Sensing* 14.4 (jan. 2022), p. 979. DOI : [10.3390/rs14040979](https://doi.org/10.3390/rs14040979).
7. Hengshuang ZHAO et al. *Pyramid Scene Parsing Network*. Avr. 2017. DOI : [10.48550/arXiv.1612.01105](https://doi.org/10.48550/arXiv.1612.01105). arXiv : [1612.01105](https://arxiv.org/abs/1612.01105) [cs].

## 8 Annexes

### Point d'intérêt

Le but d'un point d'intérêt est de permettre à un algorithme de déterminer que deux objets sont bien les mêmes sur deux images différentes en ayant appliqué des modifications telles qu'un changement d'échelle, une rotation, une translation ou même une variation de l'intensité lumineuse. L'idée est donc de trouver des points caractéristiques sur les images récupérées de manière à ce que ces points décrivent au mieux l'objet en cours de traitement. En regroupant ces points caractéristiques, appelés "points d'intérêts", on est capable de déterminer si deux objets avec un point de vue différent sont les mêmes ou non. Les méthodes d'extractions de POI les plus populaires sont les méthodes SIFT et ORB par exemple. Une fois un point d'intérêt détecté, on veut être capable de résumer son information d'une manière simple afin de pouvoir le comparer à d'autres points d'intérêts. On peut utiliser l'intensité lumineuse ou le gradient des pixels environnant le point d'intérêt pour former un descripteur correct, tout en respectant les règles de discrimination et d'invariance. Les descripteurs sont en général stockés dans des vecteurs de 128 bits, ce qui permet une comparaison rapide. Un exemple d'appariement des POI est présenté dans la Figure 17.

La comparaison entre deux descripteurs se fait généralement par des calculs booléens tels que le montre la Figure 18.




FIGURE 17 – Exemple d'association de POI.



FIGURE 18 – Association de descripteur avec une opération booléenne.

## FAST

Cette méthode d'extraction de POI vérifie pour chaque pixel de l'image d'intensité  $I_p$  si au moins 12 des pixels du cercle autour du pixel ont une intensité supérieure ou inférieure à une proportion de  $I_p$ . Autrement dit on regarde s'il y a une grosse démarcation d'intensité entre le pixel et ses voisins comme le montre la Figure 19.




FIGURE 19 – Cercle de supériorité associé à un pixel.

## BRIEF

Des paires de pixels autour du POI sont générées aléatoirement et des tests de supériorités sont effectués dessus. Un vecteur descripteur issu de la concaténation des résultats de ces tests de supériorité est créé. Un exemple est présenté dans la Figure 20.




FIGURE 20 – Exemple de paires de pixels à tester.

## Communication

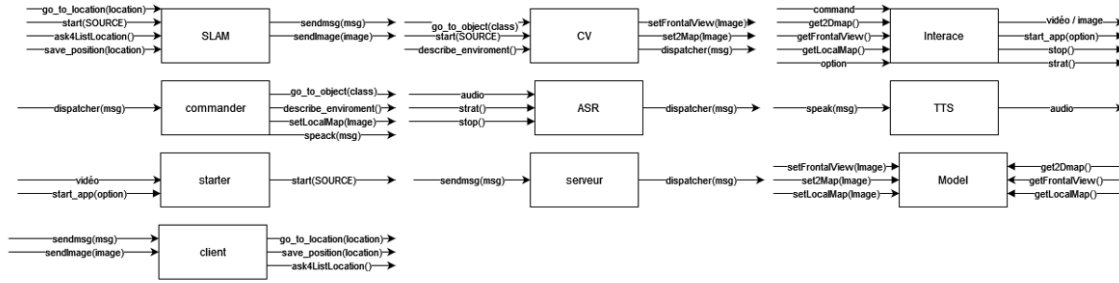


FIGURE 21 – Schéma de commandes du projet.

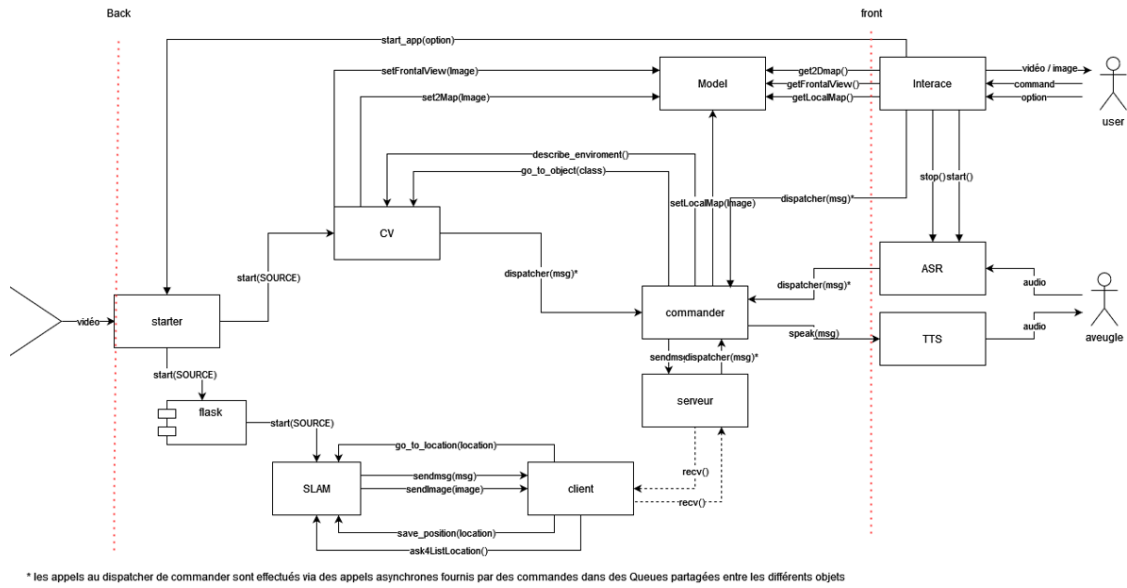


FIGURE 22 – Schéma d'interactions du projet.

## Acronymes

**BRIEF** Binary Robust Independent Elementary Features.

**CNN** Convolutional Neural Network.

**CPU** Central Processing Unit.

**CV** Computer Vision.

**DBoW2** Dynamic Bag of Words.

**EA** État de l'art.

**ESN** Entreprise de Services Numériques.

**FAST** Features from accelerated segment test.

**FYW** Find Your Way.

**ICP** Iterative Closest Point.

**IMU** Inertial Measurement Unit.

**NLP** Natural Language Processing.

**ORB** Oriented FAST and Rotated BRIEF.

**POC** Proof of Concept.

**POI** Point of Interest.

**RGB-D** Red, Green, Blue and Depth.

**ROS** Robot Operating System.

**SLAM** Simultaneous Localization and Mapping.

**TSDF** Truncated Signed Distance Fields.

**VIO** Visual-Inertial Odometry.

**VM** Virtual Machine.

**WSL2** Windows Subsystem for Linux 2.